지역 기반 고객 구매 패턴 분석

모두의 연구소 AIFFEL 프로덕트 데이터 분석가 2기

C4ward (C4 + Forward)
팀장: 김지수
팀원: 서민영, 임수명, 최재우, 최영서

목차

1 데이터 소개

2 목적 및 기대효과/ 가설설정

3 Feature Engineering

4 EDA 및 시각화

5 지역별 군집분석

6 결론 및 시사점

역할 분담

1. 리더 (김지수): 전체 일정 관리, 팀원 의견 조율, 최종 발표자료 취합

2. 데이터 전처리 담당 (김지수, 최영서): 데이터 클리닝, 결측치/이상치 처리, 테이블 병합

3. EDA 및 시각화 담당 (최재우): 다양한 그래프로 인사이트 도출, 가설 검증 시각화

4. 모델링 담당 (임수명, 서민영): 머신러닝 모델 구현, 성능 평가, 하이퍼파라미터 튜닝

데이터 소개

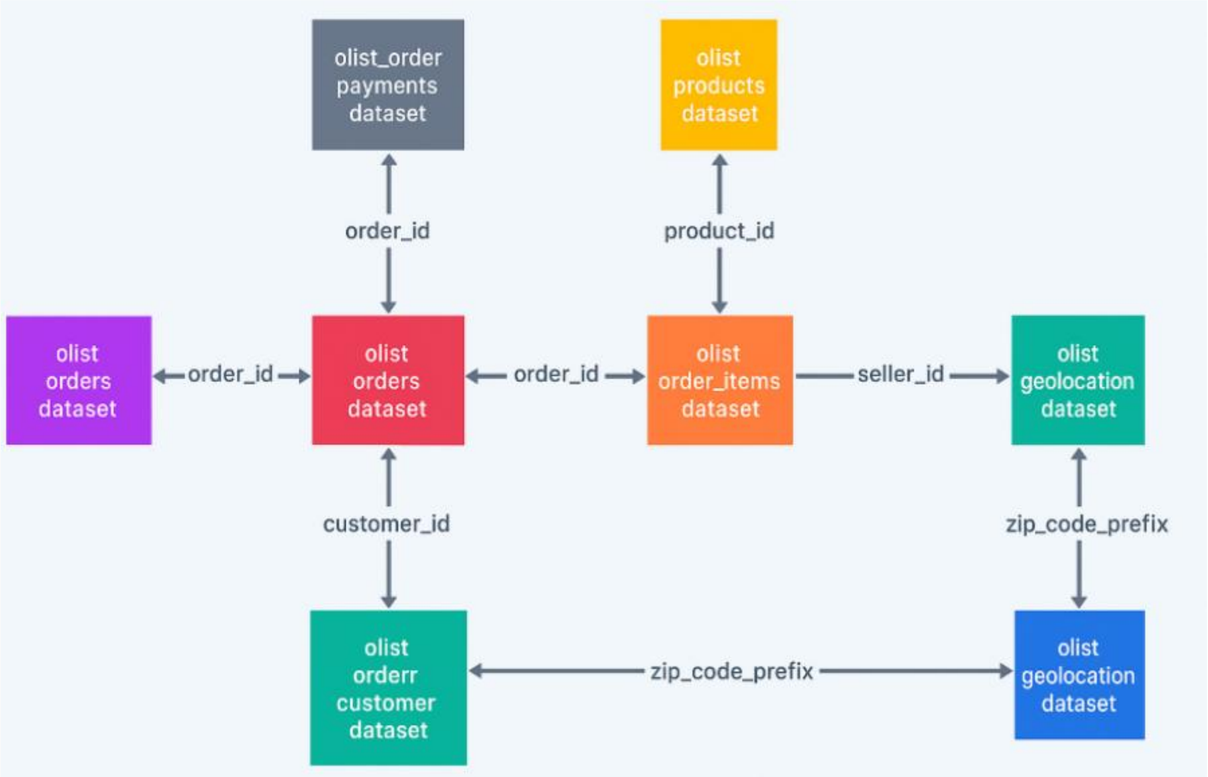

브라질 Olist 이커머스 플랫폼 공개 데이터 (2016-2018년)

연결 관계

- order_id, product_id 등 고유 ID로 연결

핵심 테이블

- olist_customers_dataset를 중심으로 시작

순차적 합병

- order_id로 주문-상품, 주문-결제, 주문-리뷰 정보 연결
- customer_id로 고객 정보 연결
- seller_id로 판매자 정보 연결
- product_id로 상품 정보 연결

불필요한 컬럼 제거

- 분석에 필요 없는 컬럼들(예: 상품 설명 길이, 리뷰 제목 등)을 삭제

결측치(NaN) 처리

- 주요 컬럼의 빈 값을 확인하고 결측치 개수가 많은 경우 다른 값을 대체(-99, Un k n own)

주문 상태 필터링

- 'canceled''된 주문만 남겨 취소된 거래 데이터 확보

주제 선정

주제: 지역 기반 고객 구매 패턴 분석

한국의 면적 X 85 → 브라질의 면적

지역에 따라 다른 형태의 고객 구매 패턴이 나올 것이다!

데이터 소개

데이터셋1
merged_orders

- 분석에 필요한 모든 데이터를 통합한 데이터셋

컬럼명	설명
customer_id	고객 id
region	지역
order_id	주문 id
order_status	주문상태
payment_type	결제유형
payment_installments	할부개수
paymnet_value	결제 금액
review_score	리뷰 점수
date	구매일
timestamp	구매 시간
product_category_name	카테고리명(포르투갈)
product_category_name_englishname	카테고리명(영어)
main_category	세부 카테고리

데이터셋2
merged_customer

- 데이터 목적: EDA 및 모델 생성에 필요한 데이터셋

컬럼명	설명
customer_id	고객 id
order_id	주문 횟수
payment_value	지출금액
order_spent	고객 별 구매당 평균 지출금

목적 및 기대효과

목적

- 브라질 고객들의 지역 정보와 구매 행동 데이터를 기반으로 군집화하여 서로 유사한 특성을 가진 고객 그룹을 식별

- 이렇게 분류된 군집을 통해 지역별로 어떤 유형의 고객이 주로 분포하는지를 분석하고, 지역별 마케팅 전략 수립에 활용

기대효과

이익 창출

- 지역별 고객군의 세부 특성을 체계적으로 이해함으로써 마케팅 효율성을 높임
- 맞춤형 프로모션 및 서비스 제공을 통해 고객 만족도와 충성도를 제고

셀러 지원

- 유지 고객의 특성과 행동 패턴을 분석하여 셀러들이 활용할 수 있는 유용한 고객 정보를 제공

- 고가치 지역과 상품 구매 패턴을 반영하여 셀러 유치 활동을 효과적으로 지원

가설설정

1. 브라질은 지리적으로 국토가 광대해 다양한 기후대가 분포하며, 지역별로 상이한 생활 방식이 형성되어 있다.
따라서, 지역마다 서로 다른 고객 유형과 소비 행태가 나타날 것이다.
즉, 5개 지역의 군집 분석 결과가 각각 다를 것이다.

2. 평균 구매 금액이 높은 지역과 낮은 지역은 특정 권역에 집중되어 있으며,
이들 간의 차이가 뚜렷하게 나타날 것이다.

3. 대부분의 지역에서 저녁 6시부터 8시 사이에 구매 비율이 가장 높게 나타나고,
반대로 새벽 12시부터 5시 사이에는 구매 비율이 가장 낮을 것이다

Feature Engineering

브라질은 27개의 주로 구성

SP', 'SC', 'MG', 'PR', 'RJ', 'RS', 'PA', 'GO', 'ES', 'BA', 'MA', 'MS', 'CE', 'DF', 'RN', 'PE', 'MT', 'AM', 'AP', 'AL', 'RO', 'PB', 'TO', 'PI', 'AC', 'SE', 'RR']

브라질 지리통계원의 지리적 구획 체계에 기반하여 5개의 대지역으로 나눔

[남동부, 남부, 북동부, 중서부, 북부]

5개 대지역으로 묶으면 각 그룹이 커져서 표본이 충분히 확보
평균치·분포의 통계적 신뢰도가 올라감

Feature Engineering

가구/집	패션/잡화	유아/어린
전자/IT	식품/음료	취미/여가
책/문화	산업/기타	Unknown

'product_category_name_english' 컬럼

총 71개의 category_name 출력

'main_category' 컬럼
유사 카테고리를 묶어
9개의 카테고리로 재분류

결측값은 Unknown으로 분류

데이터 구성 요약

고객/주문 정보:

- customer_id, order_id, order_count, order_spent, review_score, order_status

결제 정보:

- payment_value_x, payment_value_y, payment_type, payment_installments, avg_spent_per_order

지역/시간 정보:

- region, date
- 시간대 더미 변수: timestamp_새벽, timestamp_오전, timestamp_오후, timestamp_저녁

제품 분류:

- product_category_name, product_category_name_english, main_category
- 카테고리 그룹 더미: category_group_가구/집, category_group_기타, category_group_문화, category_group_소비 생활용품군, category_group_유아/어린이, category_group_전자/IT

결측치 확인

```
df.isnull().sum()
```

```
customer_id                       0
order_count                       0
payment_value_x                   0
order_spent                       0
region                            0
order_id                          0
order_status                      0
payment_type                      0
payment_installments              0
payment_value_y                   0
review_score                      0
date                              0
product_category_name          3303
product_category_name_english  3330
```

product_category_name (3,303건)

product_category_name_english (3,330건)

→ 시각화 분석 시 해당 행은 제거하거나 기타 처리 필요

분석주제

- **카테고리별 구매 비율 (지역 기준)**
  - 지역마다 인기 있는 제품군 파악 → 지역 맞춤 마케팅
- **지역별 평균 구매 금액**
  - 지역별 구매력 또는 고가 제품 선호도 비교
- **지역별 구매 시간대 패턴**
  - 마케팅 캠페인 타이밍 최적화
- **지역별 취소율 ('canceled' 비율)**
  - 지역별 취소율 파악
- **지역별 평균 리뷰 점수**
  - 고객 만족도 지역별 편차 확인
- **결제유형 / 할부 수 분포 (지역별)**
  - 지역별 소비 습관 차이 이해 (카드 사용/할부 선호 등)
- **구매 수 대비 총 지출 금액 (1인당 평균)**
  - 지역별 구매 빈도 vs 지출 간 균형 분석

EDA 및 시각화

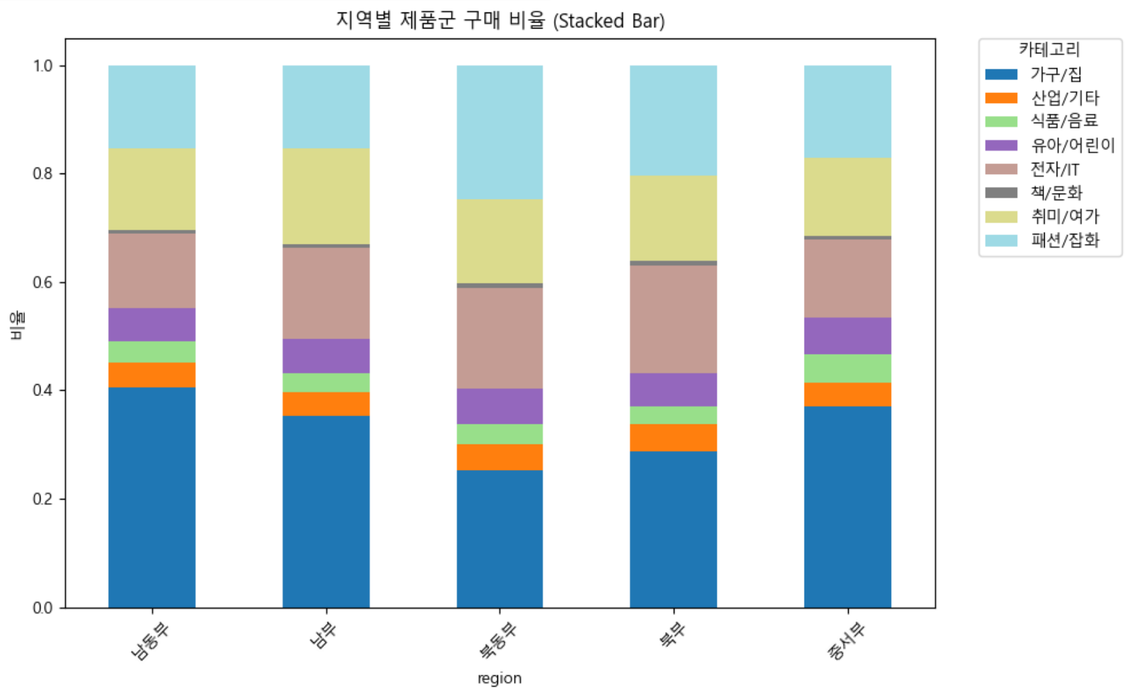

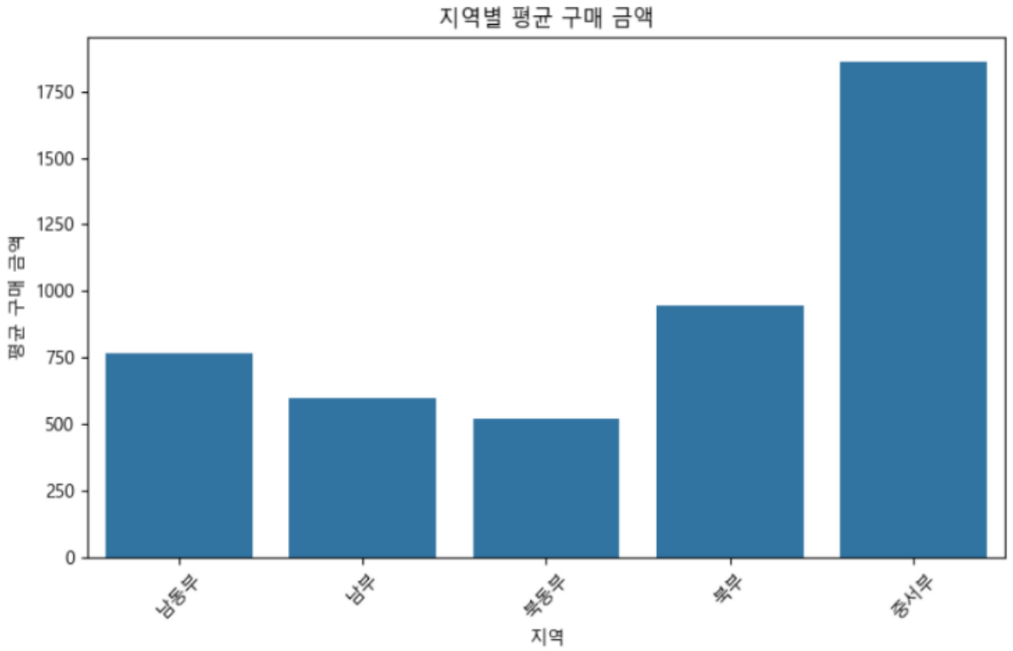

가구/집 카테고리 비중이 모든 지역에서 가장 높은 비율을 차지함
북동부에서는 패션 잡화의 구매 비율이 타 지역보다 높음
그러나 대부분의 제품군은 지역 간 차이가 크지 않아 보임

중서부>북부>남동부>남부>북동부 순으로 주문수가 많은 것으로 확인됨

EDA 및 시각화

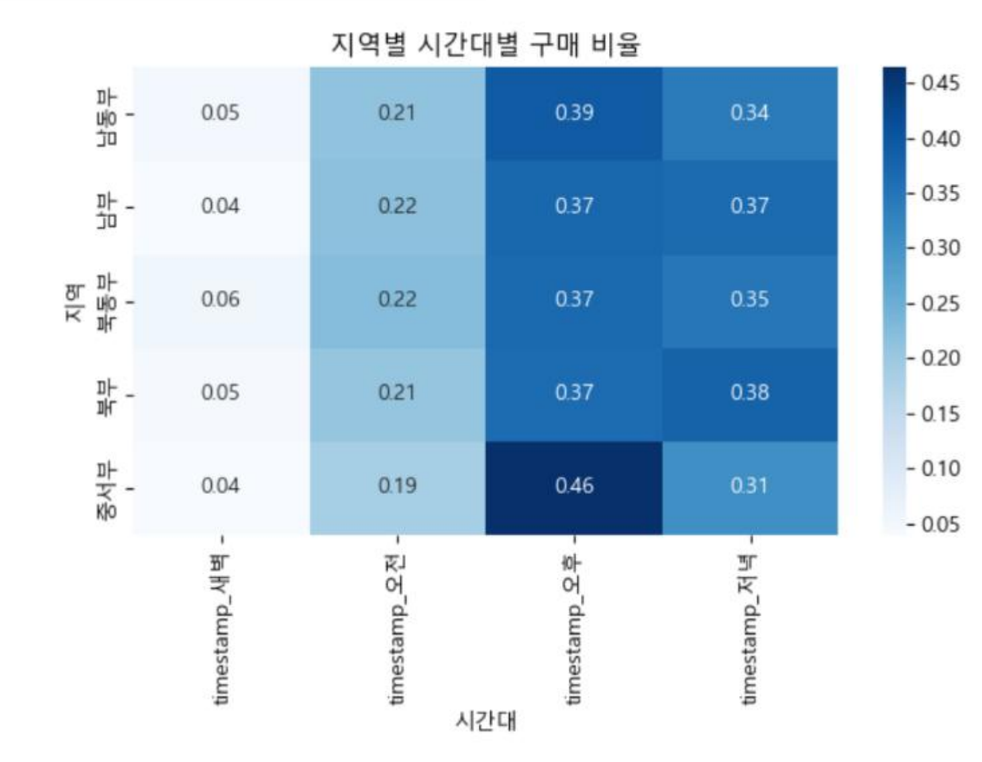

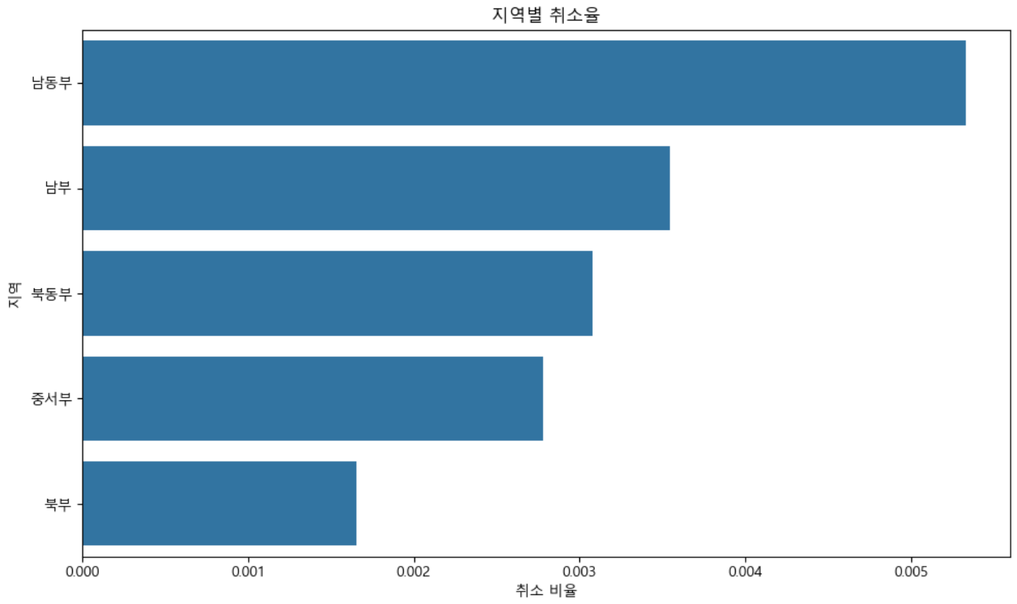

전체적으로 '오후'와 '저녁' 시간대가 주 구매 시간대
특히 중서부는 오후 시간대 구매 비율이 0.46로 전체 최고치, → 오후 활동 중심 지역으로 볼 수 있음
북부 지역은 저녁 구매 비율이 가장 높음
전체 지역에서 새벽 시간대 구매는 4~6% 수준으로 가장 낮음

남동부가 약 0.52%로 가장 높은 반면,
북부는 0.16%로 가장 낮음

EDA 및 시각화

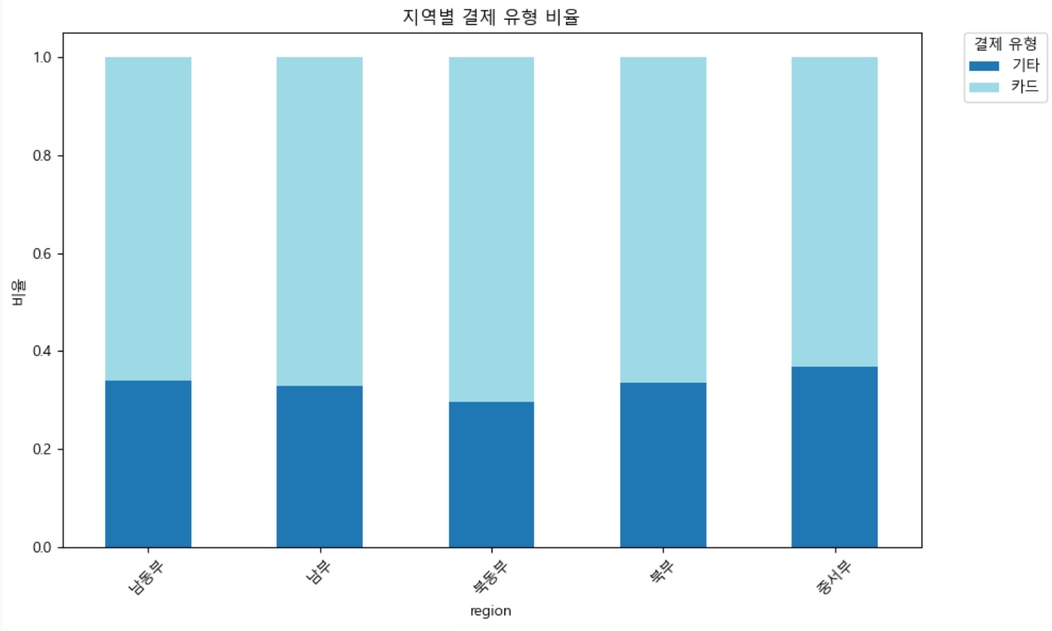

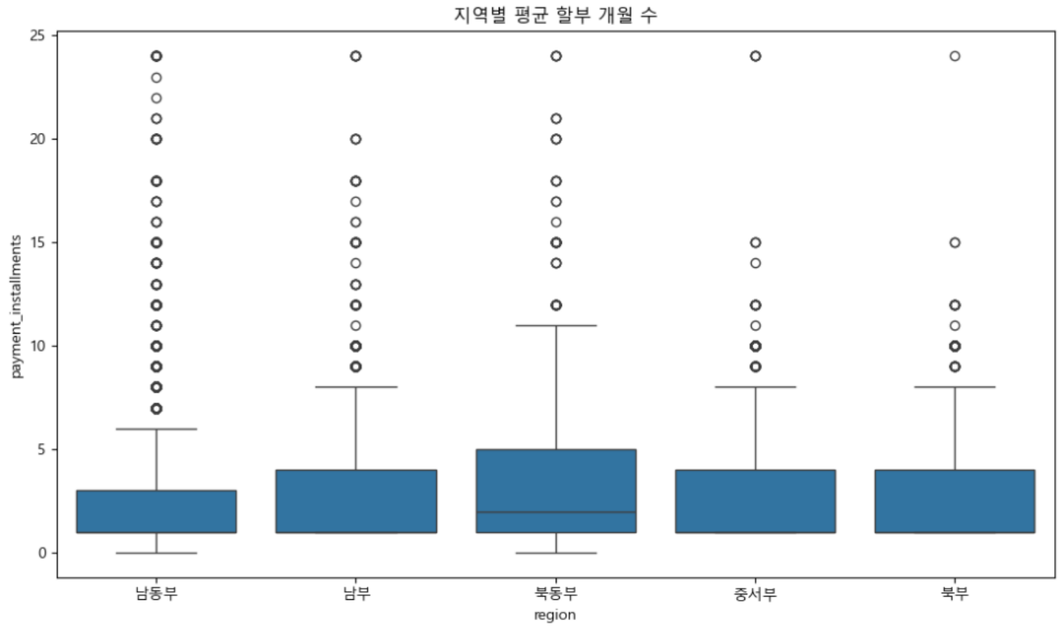

모든 지역에서 카드 결제 유형이 약 70% 내외로 우세함
북부는 기타(바우처, 상품권 등)결제 유형이 약 32%
수준으로 최고치를 나타냄

대부분의 지역에서 2~3개월 중심의 단기 할부 사용이
일반적임 북동부 지역은 장기 할부 이용자도 분포

EDA 및 시각화

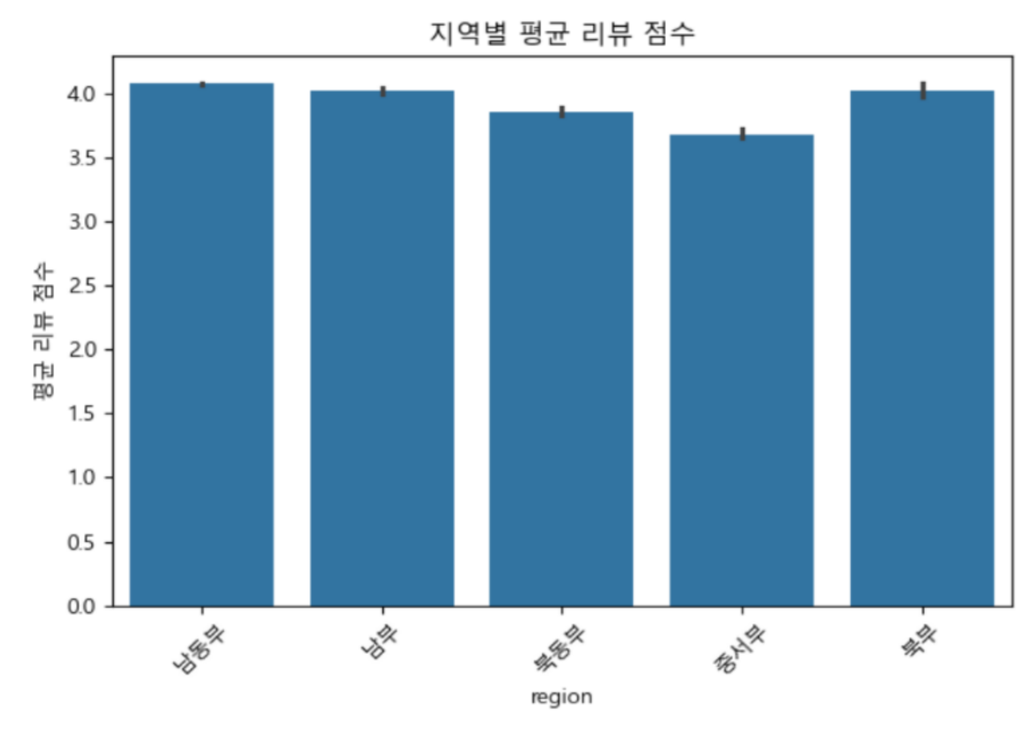

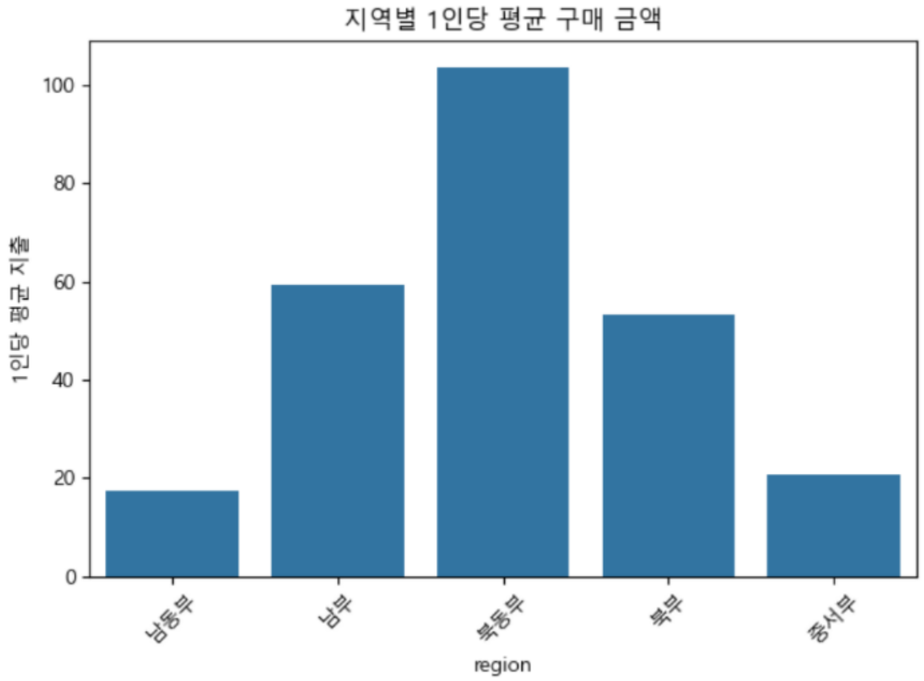

모든 지역의 평균 점수가 3.7 이상,
전반적으로 만족도 수준이 높은 고객층으로 해석됨

북동부 지역의 구매 금액이 압도적으로 높음
남부, 북부는 중간 수준
중서부, 남동부는 평균 금액이 낮음

이상치 처리

```python
from scipy.stats import zscore

target_cols = ['payment_value_x', 'order_spent', 'payment_installments', 'payment_value_y']
z_scores = df[target_cols].apply(zscore)

# 이상치 여부 마스크 생성
outlier_mask = (z_scores.abs() >= 3)

# 하나라도 이상치가 있는 행: True → 제거 대상
row_outlier_mask = outlier_mask.any(axis=1)

# 이상치 제거 후 데이터셋
df_cleaned = df[~row_outlier_mask]  # 이상치가 아닌 행만 남김

# 결과 확인
print(f"원본 데이터 행 수: {df.shape[0]}")
print(f"이상치 제거 후 행 수: {df_cleaned.shape[0]}")
```

```
원본 데이터 행 수: 137113
이상치 제거 후 행 수: 131410
```

- int, float만을 가진 컬럼들을 기준으로 이상치 여부를 확인 후 추출
- z_scores.abs() >= 3으로 하여 정상 데이터 손실을 최소화하면서 극단값만 제거
- 원본 데이터 행 수 에서 13,7113에서 이상치 제거 후 13,1410 남음

이상치 처리

```python
from scipy.stats import zscore

# 그룹화된 데이터 생성
category_by_region = df_cleaned.groupby(['region', 'product_category_name_english']) \
                                .size().reset_index(name='count')

# z-score 계산
category_by_region['zscore'] = zscore(category_by_region['count'])

# 이상치 탐색: z-score가 절대값 3 이상인 경우
outliers = category_by_region[category_by_region['zscore'].abs() >= 3]

# 결과 출력
outliers
```

	region	product_category_name_english	count	zscore
7	남동부	bed_bath_table	11776	9.770747
15	남동부	computers_accessories	5689	4.544050
39	남동부	furniture_decor	7586	6.172939
43	남동부	health_beauty	7140	5.789974
49	남동부	housewares	6407	5.160572
64	남동부	sports_leisure	6905	5.588187
69	남동부	watches_gifts	4126	3.201956

- Region과 poduct_category_name_english를 기준으로 z_score로 이상치를 확인
- 7개의 행이 출력되었지만 count를 보면 이 조합에 해당하는 갯수를 확인 가능
- 이상치를 제거하면 총 49,629건이 삭제 아래와 같이 81,781건이 남음

	customer_id	order_count
0	00012a2ce6f8dcda20d059ce98491703	1
2	0001fd6190edaaf884bcaf3d49edf079	1
3	0002414f95344307404f0ace7a26f1d5	1
6	000419c5494106c306a97b5635748086	1
7	00046a560d407e99b969756e0b10f282	1
...	...	...
131402	fffecc9f79fd8c764f843e9951b11341	9
131403	fffecc9f79fd8c764f843e9951b11341	9
131404	fffecc9f79fd8c764f843e9951b11341	9
131405	fffecc9f79fd8c764f843e9951b11341	9
131406	fffeda5b6d849fbd39689bb92087f431	1

81781 rows × 27 columns

이상치 처리

```
df.isnull().sum()
```

```
customer_id                     0
order_count                     0
payment_value_x                 0
order_spent                     0
region                          0
order_id                        0
order_status                    0
payment_type                    0
payment_installments            0
payment_value_y                 0
review_score                    0
date                            0
product_category_name           0
product_category_name_english   0
main_category                   0
avg_spent_per_order             0
timestamp_새벽                    0
timestamp_오전                    0
timestamp_오후                    0
timestamp_저녁                    0
category_group_가구/집              0
category_group_기타               0
category_group_문화               0
category_group_소비 생활용품군          0
category_group_유아/어린이            0
category_group_전자/IT            0
canceled                        0
dtype: int64
```

- 결측치 제거된걸 확인 할 수 있음

이상치 처리

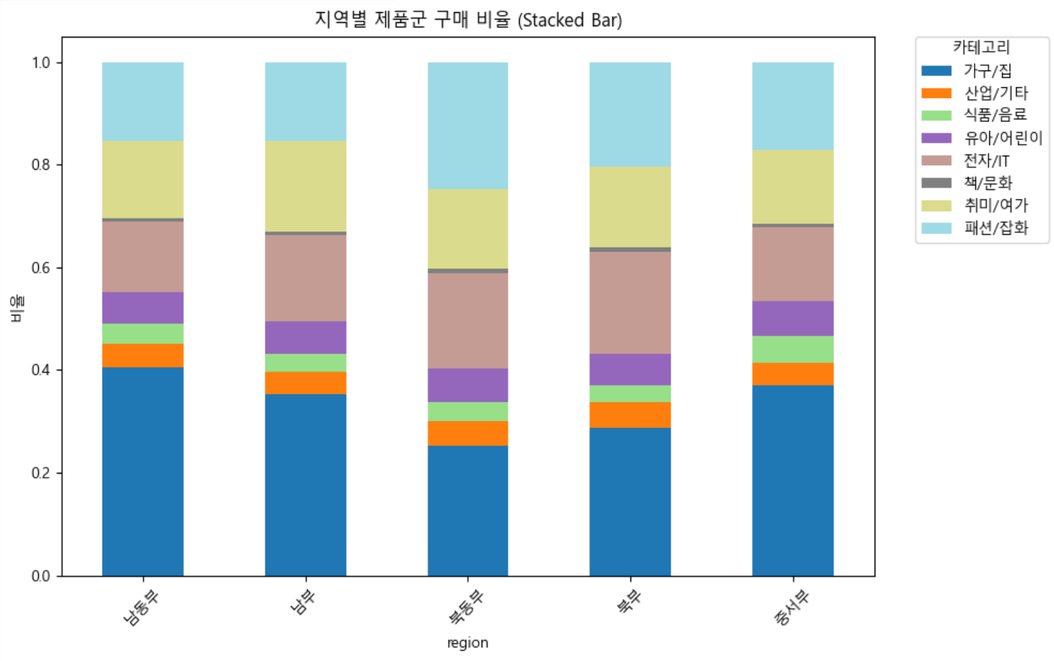

이상치 처리 전

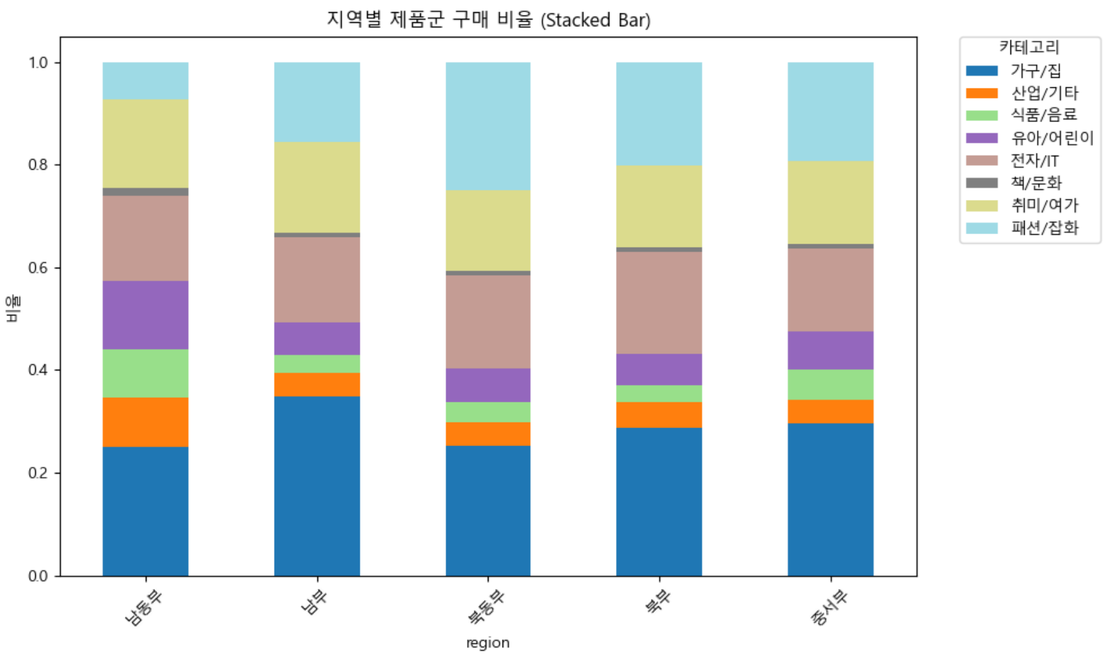

이상치 처리 후

이상치 처리

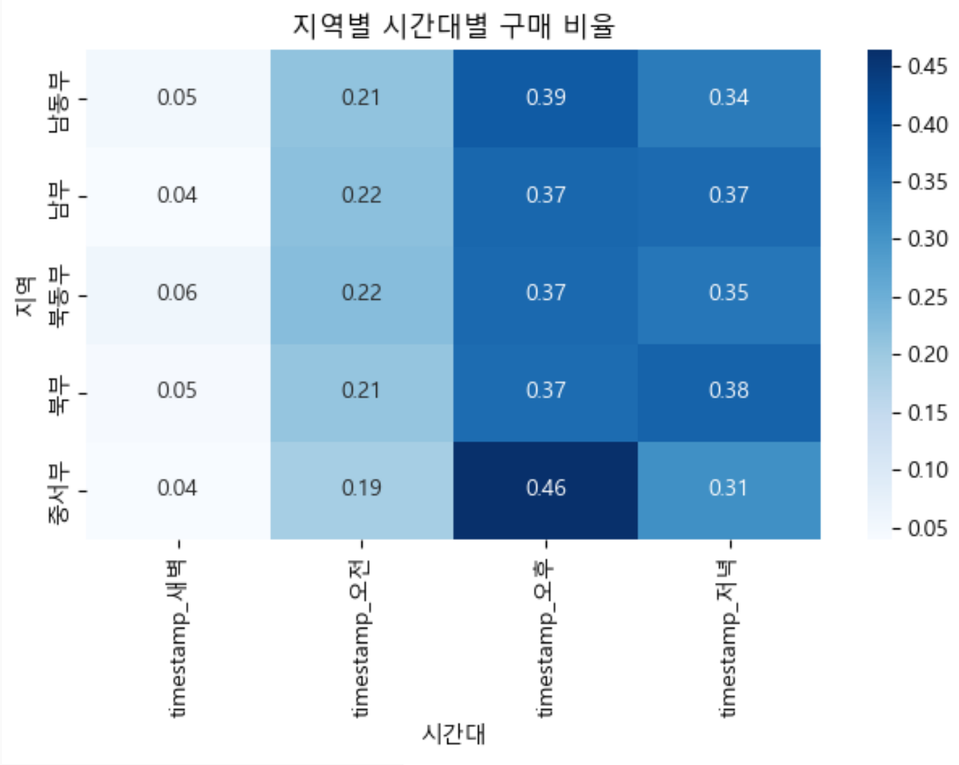

이상치 처리 전

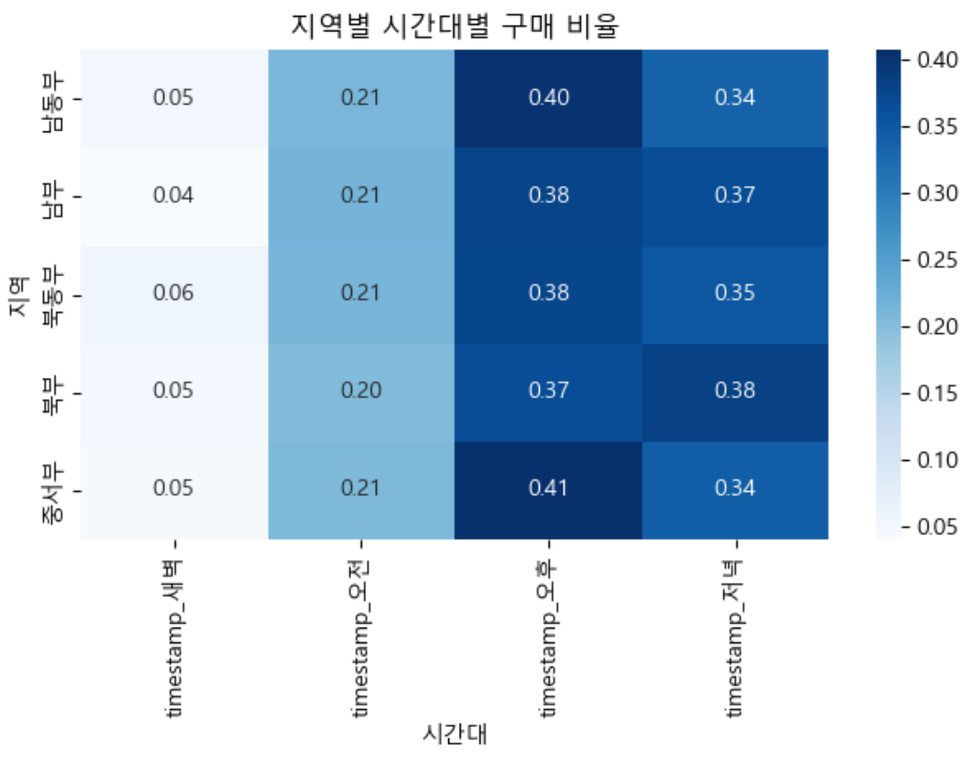

이상치 처리 후

이상치 처리

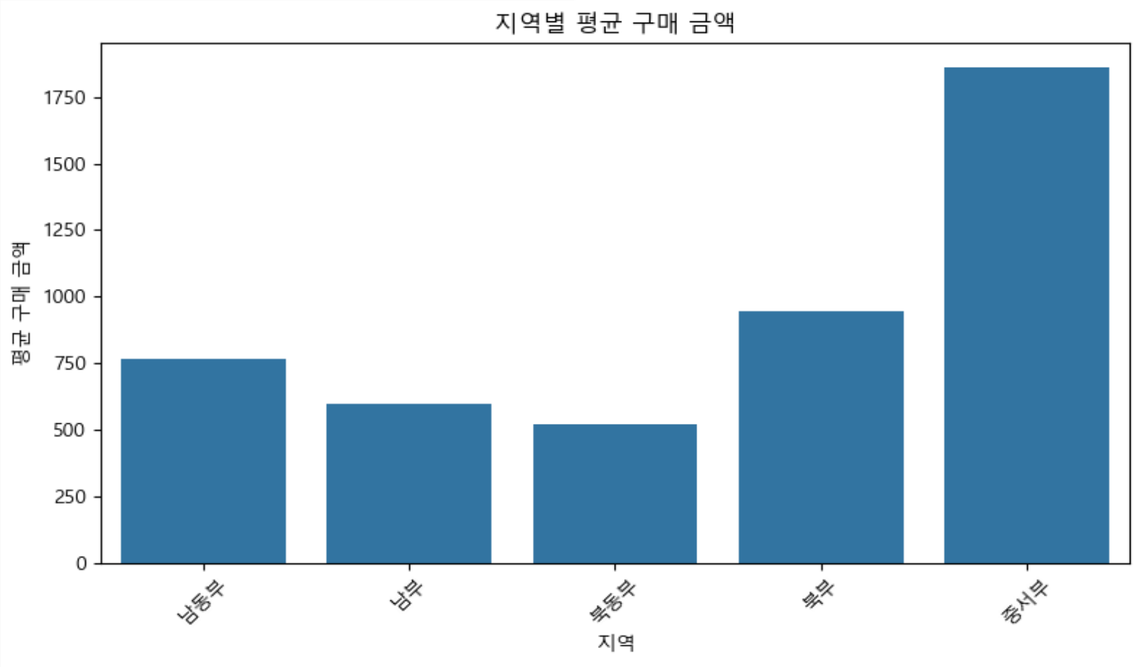

이상치 처리 전

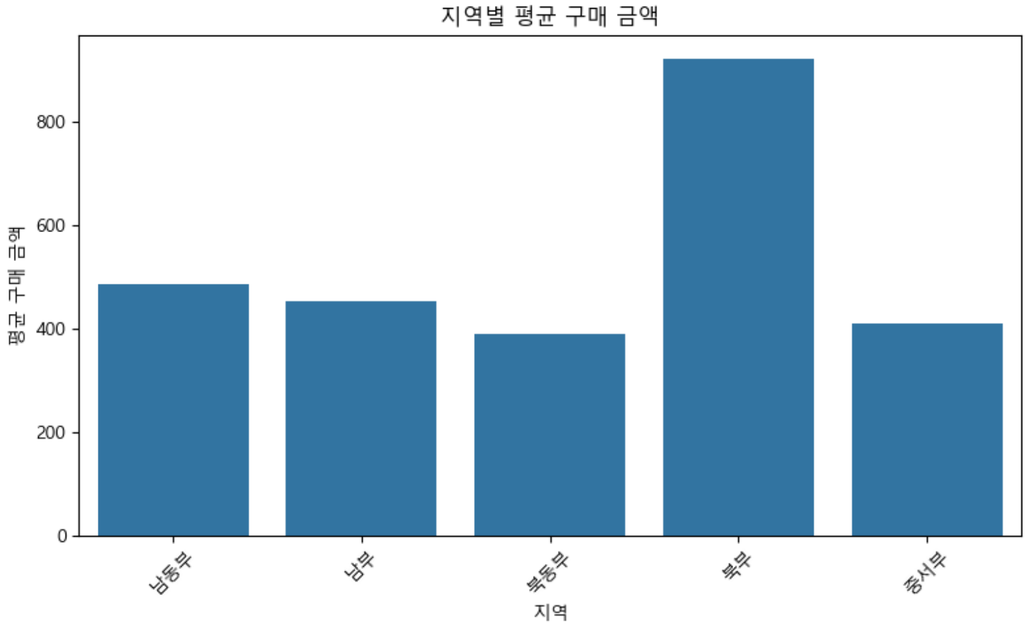

이상치 처리 후

이상치 처리

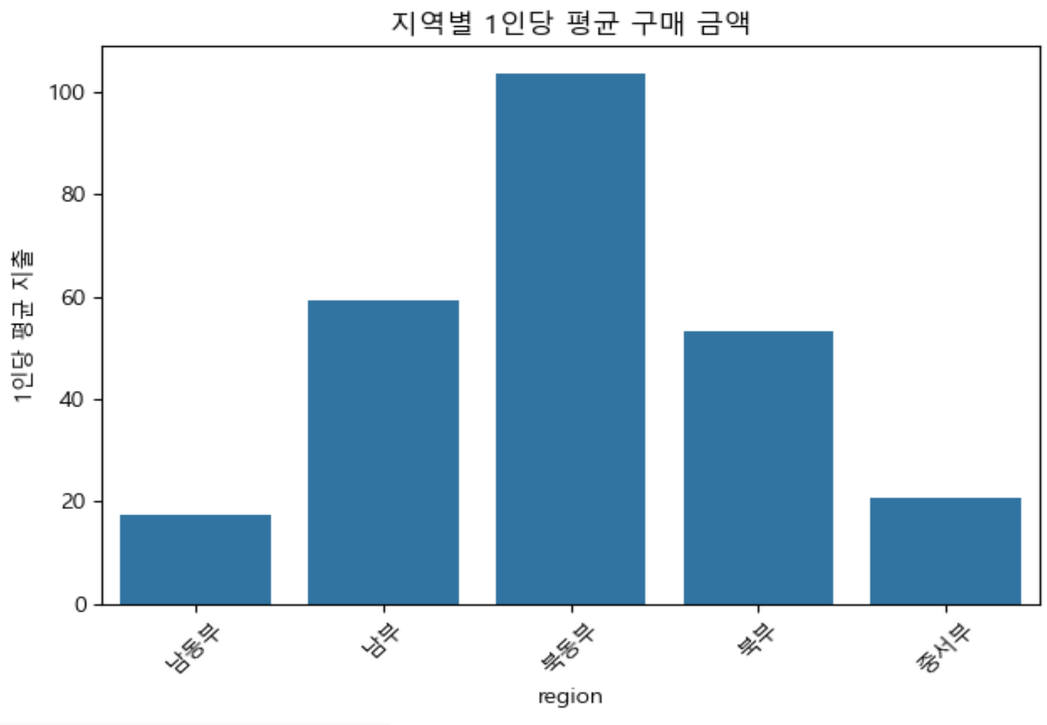

이상치 처리 전

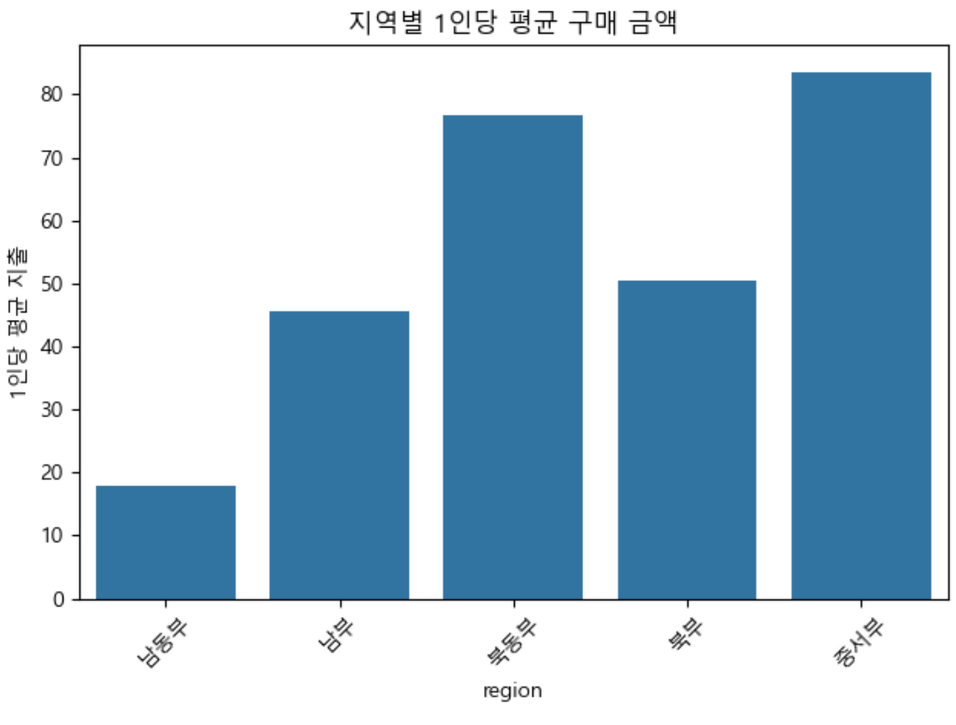

이상치 처리 후

지역별 군집 분석

K-Means 알고리즘을 선택한 이유

1. 현재 갖고있는 데이터는 주문, 결제, 시간대 등 수치, 비율 컬럼
> 정답이 없는 고객 구매 행동 로그에는 비지도 학습 기법 필요

2. 수십만 행을 빠르게 처리 가능
> DBSCAN, 계층 군집 등은 연산량이 많으면 속도 저하

3. 각 클러스터 중심의 평균 값으로 설명이 가능
> 예, 군집 2는 저녁, 저가 쇼핑 족이다.
=> 비즈니스적 인사이트 도출에 용이

4. 정규화 간소화 가능
> StandardScaler + 원-핫 인코딩

5. 클러스터 수 계산 및 정확히 지정 가능

지역별 군집 분석

MinMaxScaler 대신 StandardScaler를 쓴 이유는?

1. 우리는 금액, 횟수, 시간대 등 다양한 분포가 혼합된 데이터를 다룸
=> StandardScaler가 과도한 왜곡 없이 전체 분포 균형을 맞추기에 더 적합

2. 상대적으로 이상치에 영향을 덜 받음

3. K-Means에 더욱 적합한 정규화 방식
=> MinMaxScaler는 작고 균일한 값에 좋고,
=> StandardScaler는 거리 기반 알고리즘에 더욱 적합

지역별 군집 분석

모델링에 사용할 변수 선택하기

cluster	order_spent	payment_installments	review_score	order_count	avg_spent_per_order	timestamp_오전	timestamp_오후	timestamp_저녁	timestamp_새벽
0	451.360104	2.655064	4.02919	25.269643	150.559525	0.141211	0.858789	0	0
1	374.579886	2.775373	4.037431	6.800194	147.273444	0.034984	0.150163	0.814853	0
2	1075.395934	2.482909	3.843303	43.566271	142.659445	0.909487	0.050052	0.003662	0.036798
3	496.19951	2.832158	3.978248	15.7592	144.692103	0	0.264491	0.419577	0.315932
4	5296.749735	2.345718	4.238398	346.804696	221.150965	0.087431	0.21105	0.59558	0.105939

cluster	order_spent	payment_installments	review_score	order_count	avg_spent_per_order	timestamp_오전	timestamp_오후	timestamp_저녁	timestamp_새벽	category_group_기타	category_group_문화	category_group_소비생활용품군	category_group_유아/어린이	category_group_전자/IT
0	744.979589	2.717701	4.046211	47.733257	144.449671	0	0.164472	0.833033	0.002495	0.065303	0.165817	0.208817	0.019265	0.135791
1	810.344059	2.664319	4.050415	38.192046	154.981672	0.032119	0.874884	0.092997	0	0.069885	0.163348	0.202408	0.016717	0.154321
2	1537.618684	2.602282	3.731013	84.442549	135.679034	0.148323	0.440129	0.239138	0.17241	0.019477	0.048404	0.066613	0.641812	0.049095
3	703.35175	2.556036	3.949089	13.769504	158.276818	0.833969	0.020712	0.14532	0	0.077637	0.1651	0.217027	0.015078	0.157899
4	453.492295	2.792065	3.98206	12.000711	157.755221	0.575279	0	0	0.424721	0.095392	0.176875	0.203825	0.060065	0.168181

컬럼명	설명
order_count	주문수
order_spent	고객별 구매당 평균 지출 금액
timestamp_오전	구매 시간
timestamp_오후	구매 시간
timestamp_저녁	구매 시간
timestamp_새벽	구매 시간

지역별 군집 분석

각 지방별 / 전체 엘보우 기법을 통한 k 값

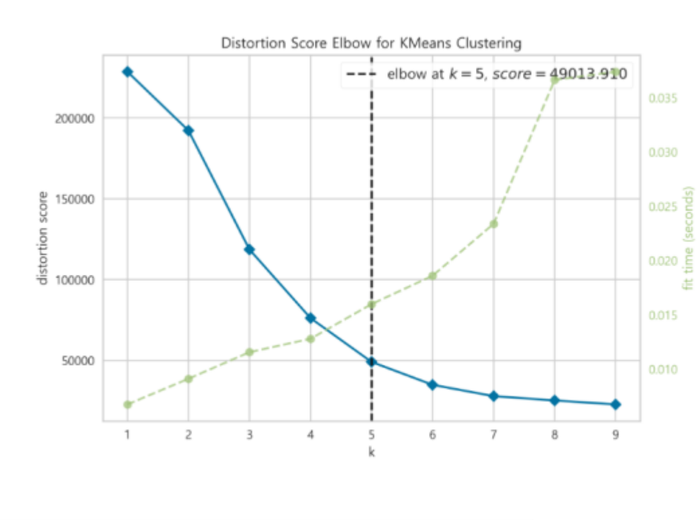

남동부

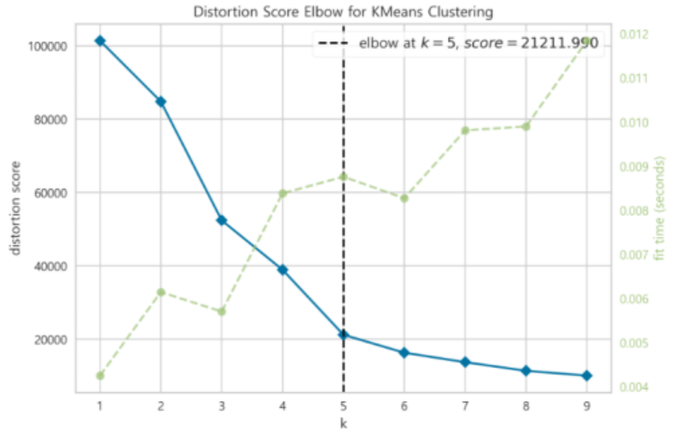

남부

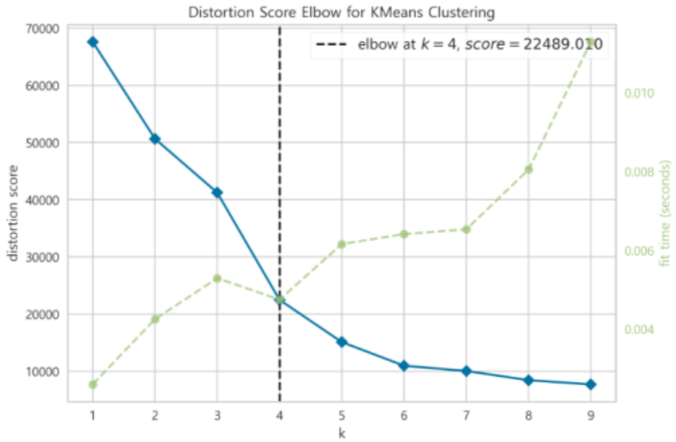

북동부

지역별 군집 분석

각 지방별 / 전체 엘보우 기법을 통한 k 값

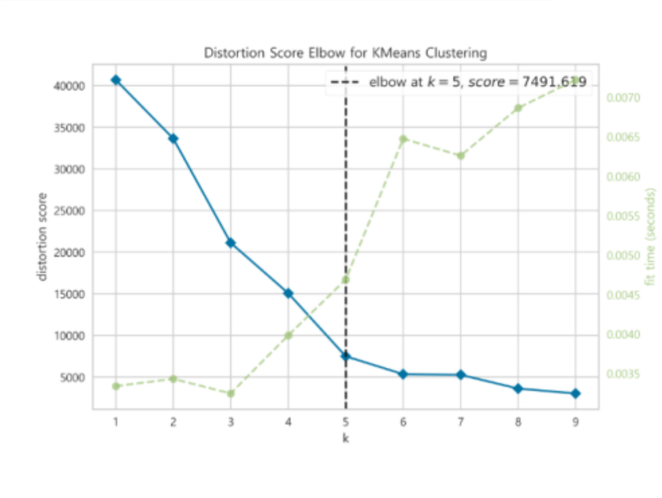

중서부

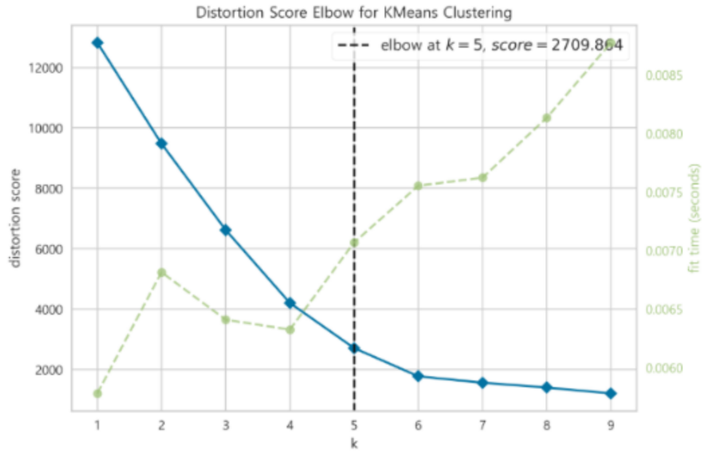

북부

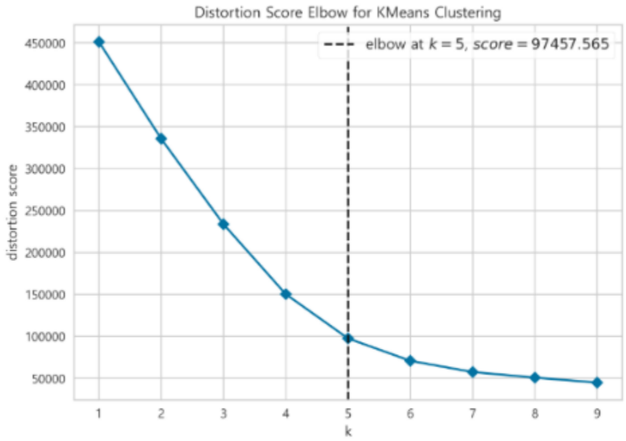

전체

지역별 군집 분석 클러스터 별 해석

	order_count (주문수)	order_spent (지출 금액)	timestamp_오전	timestamp_오후	timestamp_저녁	timestamp_새벽
cluster						
0	1.629638	206.504638	0.017219	0.24449	0.738292	0
1	1.684734	218.329763	0.001625	0.779567	0.218808	0
2	1.635231	211.393476	0.959259	0	0.040741	0
3	2.221555	317.185156	0.0015	0.205051	0.007752	0.785696
4	9.472852	1468.82712	0.191527	0.34457	0.315931	0.147971

	order_count (주문수)	order_spent (고객별 구매당 평균 지출 금액)	주요 구매 시간대	특성 요약
cluster				
0	1.63회	206.5	저녁 (73.8%)	저녁 시간대에만 활동 / 소극적 소비자
1	1.68회	218.3	오후 (77.9%)	오후에 집중된 구매 / 낮 시간 활동 중심
2	1.63회	211.4	오전 (95.9%)	오전에만 활동 / 조기 활동형 소비자
3	2.22회	317.2	새벽 (78.6%)	매우 이례적 패턴, 야행성 소비자군
4	9.47회	1468.8	다양 (오전~새벽 분포)	주문 빈도 및 지출이 가장 높고, 전 시간대에서 활동하는 충성 고객층

지역별 군집 분석 클러스터 별 해석

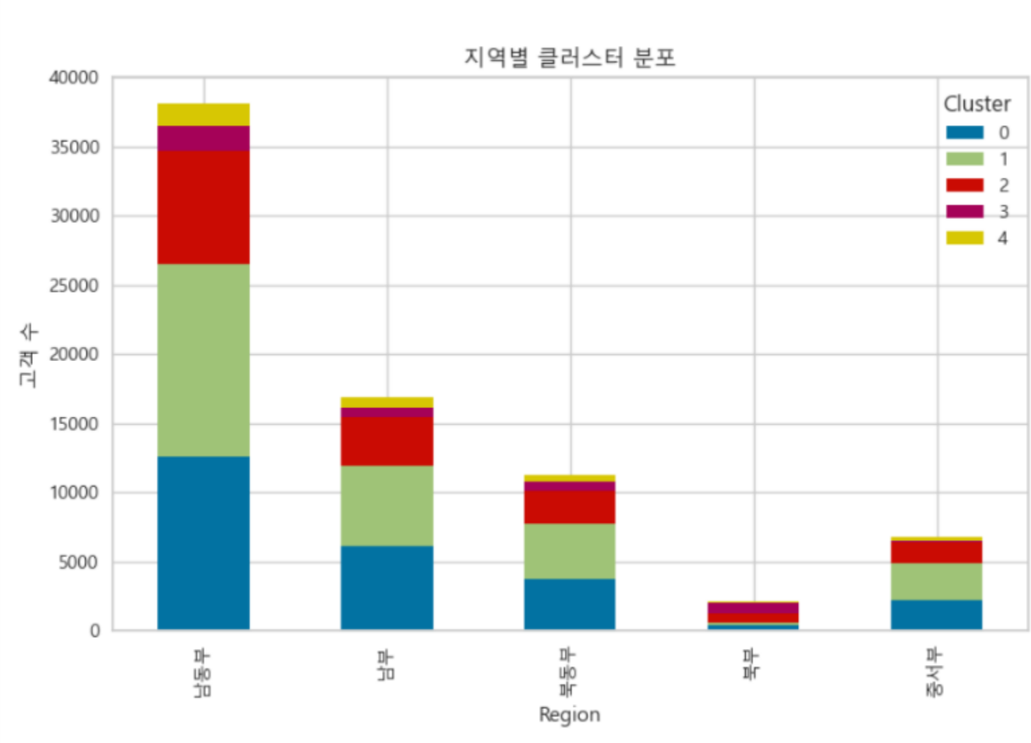

남동부: 고객 수가 가장 많고, 모든 클러스터가 고르게 분포되어 있음

남부: 균형 잡힌 분포, 클러스터 0,1 우세

북동부: 클러스터 1 강세, 유사하게 고르게 분포

북부: 클러스터 3(야간 활동 고객) 비중 높음

중서부: 클러스터 1 우세, 클러스터 3는 거의 없음-> 저녁이나 오후 소비 성향 강함, 야간 활동

cluster	0	1	2	3	4
region					
남동부	12599	13881	8246	1797	1583
남부	6134	5757	3520	696	794
북동부	3721	3966	2398	649	535
북부	432	143	664	787	111
중서부	2203	2710	1470	70	329

결론 및 시사점

1 지역별로 고객 유형과 소비 행태가 다를 것이다

결론

- 지역별 클러스터 분포 차이는 매우 뚜렷하게 나타났음
- 북부 지역은 클러스터 3(새벽 활동 고객)의 비율이 가장 높았고,
- 남동부는 클러스터 0~4가 고르게 분포하며 다양한 소비 행태가 공존
- 중서부는 특정 클러스터에 집중되어 보다 균일한 소비 특성을 보임

시사점

- 생활 방식, 인프라, 도시화 수준 등이 고객 행태에 영향을 주는 것으로 해석됨

- 지역별 맞춤 전략 수립이 필요함
  예: 북부 → 심야 배송 및 야간 마케팅 강화, 남동부 → 다층적 세분화 캠페인 실행

결론 및 시사점

2 평균 구매금액이 높은 지역은 권역별로 구분된다

결론

- 클러스터 통계 결과, 클러스터 4는 평균 주문 수, 총 지출 모두 압도적으로 높았고, 이 클러스터는 남동부 및 남부 지역에 집중되어 있음
- 북부·북동부는 전반적으로 지출 규모가 낮은 클러스터 비중이 높음

시사점

- 구매력 높은 고가치 고객이 남동부에 다수 분포하는 점은 마케팅 효율화에 중요한 단서
- 고가 고객 집중 지역에 대해 프리미엄 전략, 로열티 프로그램 등 실행 가능

결론 및 시사점

3 대부분의 구매는 저녁(6~8시), 새벽(12~5시)은 낮을 것이다

결론

- 검증 결과: 부분 채택 (일반적 경향은 맞으나 예외 있음)
- 다수의 클러스터에서 timestamp_저녁 비중이 높음
  - 예: 클러스터 0, 1에서 저녁 구매 비율이 70~80% 이상
- 그러나 일부 클러스터(예: 클러스터 3)는 새벽 비중이 70% 이상으로 매우 높았고, 이는 북부 지역에 집중됨

시사점

- 전반적으로는 저녁 구매가 많지만, 특정 지역(예: 북부)은 새벽 수요가 존재
- 따라서 시간대 마케팅 시 예외적 시간대 수요층도 고려해야 함
  - 예: 북부 대상 심야 이벤트, 새벽 배송 타겟팅

결론 페이지

항목	분석 결과	전략적 시사점
지역별 소비 특성	지역별 클러스터 차이 큼	맞춤형 마케팅 전략 필수
구매력 지역 편차	고지출 고객은 남동부/남부 집중	프리미엄 고객 집중 육성 필요
시간대별 구매 패턴	전체적으로는 저녁 > 오전 > 새벽	예외 지역 고려한 시간대 전략 수립

감사합니다.

모두의 연구소 AIFFEL 프로덕트 데이터 분석가 2기

C4ward (C4 + Forward)
팀장: 김지수
팀원: 서민영, 임수명, 최재우, 최영서